## k8s pod 监控分析

k8s 监控问题,经历了几个版本,从1.12 开始,数据从 k8s metrics api 统一获取,包含核心监控指标和自定义指标,其中核心指标(pod、node 的 cpu、内存、网络、文件等)来自于 kubelet,核心指标还用于 k8s dashboard、hpa 等。这里只说核心指标:


核心指标中和 pod、node 相关的都是由 kubelet metrics api 提供 ,kubelet 内置了 cAdvisor,cAdvisor 调用的是 libcontainer 库,libcontainer 库其实是对 cgroup 文件 的封装,所以 cAdvisor 只是个数据转发者,其数据来自于 cgroup 文件,cgroup 文件内 容举例如下:

## 说几个关键的:

cgroup 指标	cgroup 子指标	prometheus 指标	备注
memory.kmem.usage_i n_bytes		无	内核空间内存使用
memory.stat	total_inactive_fil	无	非活跃内存
	total_active_file	无	活跃内存
	total_rss	container_memory_rss	使用的物理内存,和 docker stats 相同。 docker stats 、top -p \$PID 中 RES , 看到的是这个指标。
	total_cache	container_memory_cache	缓存大小。container_memory_cache =total_inactive_file+total_active_file
memory.usage_in_byt		container_memory_usage_bytes	内存当前使用量,包含缓存。 container_memory_usage_bytes =container_memory_rss + container_memory_cache + memory.kmem.usage_in_bytes

memory.limit_in_byt	kube_pod_container_resource_limits_memo ry_bytes	内存限制的使用量
memory.max_usage_in _bytes	container_memory_max_usage_bytes	历史内存内存最大使用量
memory.failcnt	container_memory_failcnt	内存使用量达到限制值的次数
	container_memory_working_set_bytes	内存工作集(working set)使用量,也是 limit 限制时的 oom 判断依据。 kubectl top pod 看到的是这个指标。 container_memory_working_set_bytes = container_memory_usage_bytes - total_inactive_file

## 下面是一个实例,可以用来验证上述公式,此次的container\_memory\_working\_set\_bytes=1148772352



[root@k8s-uat-10-12-15-9 poddd34bb14-5c9c-417b-920d-2f6aedf0a136]# cat memory.kmem.usage\_in\_bytes 10342400 [root@k8s-uat-10-12-15-9 poddd34bb14-5c9c-417b-920d-2f6aedf0a136]# [root@k8s-uat-10-12-15-9 poddd34bb14-5c9c-417b-920d-2f6aedf0a136]# [root@k8s-uat-10-12-15-9 poddd34bb14-5c9c-417b-920d-2f6aedf0a136]# cat memory.usage\_in\_bytes 1148776448 [root@k8s-uat-10-12-15-9 poddd34bb14-5c9c-417b-920d-2f6aedf0a136]#

```
[root@k8s-uat-10-12-15-9 poddd34bb14-5c9c-417b-920d-2f6aedf0a136]# cat
memory. stat
cache 0
rss 0
rss_huge 0
mapped_file 0
swap 0
pgpgin 0
pgpgout 0
pgfault 0
pgmajfault 0
inactive anon 0
active_anon 0
inactive\_file\ 0
active file 0
unevictable 0
hierarchical_memory_limit 2097152000
hierarchical_memsw_limit 9223372036854771712
total cache 929800192
total rss 208633856
total_rss_huge 0
total mapped file 0
total_swap 0
total_pgpgin 190186677
total_pgpgout 189908739
total_pgfault 70004868
total_pgmajfault 1
total inactive anon 0
total active anon 208633856
total_inactive_file 4096
total active file 929796096
total unevictable 0
```

```
| TootekAs-uat-10-12-15-9 | poddd34bb14-5c9c-417b-920d-2f6aedf0a136|# | cat memory.kmem.usage_in_bytes | 10342400 | rootekAs-uat-10-12-15-9 | poddd34bb14-5c9c-417b-920d-2f6aedf0a136|# | cat memory.stat | cache 0 | ross 0 |
```

对于 cgroup 中没有的指标, cAdvisor 是计算出来的, 找到相关的源码

container\_memory\_working\_set\_bytes = container\_memory\_usage\_bytes total\_inactive\_file

## 对应源码是:

```
ret.Memory.Cache = s.MemoryStats.Stats["total_cache"]
    ret.Memory.RSS = s.MemoryStats.Stats["total_rss"]
ret.Memory.Swap = s.MemoryStats.Stats["total_swap"]
    ret.Memory.MappedFile = s.MemoryStats.Stats["total_mapped_file"]
  ret.Memory.Cache = s.MemoryStats.Stats["cache"]
    ret.Memory.RSS = s.MemoryStats.Stats["rss"]
ret.Memory.Swap = s.MemoryStats.Stats["swap"]
    ret.Memory.MappedFile = s.MemoryStats.Stats["mapped_file"]
if v, ok := s.MemoryStats.Stats["pgfault"]; ok {
  ret.Memory.ContainerData.Pgfault = v
    ret.Memory.HierarchicalData.Pgfault = v
if v, ok := s.MemoryStats.Stats["pgmajfault"]; ok {
     ret.Memory.ContainerData.Pgmajfault = v
    ret.Memory.HierarchicalData.Pgmajfault = v
workingSet := ret.Memory.Usage
if v, ok := s.MemoryStats.Stats["total_inactive_file"]; ok {
     if workingSet < v {</pre>
        workingSet = 0
         workingSet -= v
ret.Memory.WorkingSet = workingSet
```